

Taller de programacio2n

TRABAJO PRÁCTICO N° 4

CLASIFICANDO INFORMALES EN LA EPH: MÉTODOS DE REGULARIZACIÓN & CART

Fecha de entrega: viernes 4 de septiembre a las 13:00 hs.

Contenido: Aplicar los métodos de regularización y árboles de regresión vistos en clase en la EPH para predecir la informalidad en 2025. Discutir las métricas de desempeño de clasificación y evaluar entre modelos la identificación de informales en una región argentina.

Modalidad de entrega

- Crear en el repositorio público de GitHub una carpeta llamada **TP4** con el código utilizado para resolver el trabajo práctico, indicando claramente a qué inciso corresponde cada parte.
- Incluir en esa carpeta el informe final en PDF, con gráficos e imágenes integrados, nombrado **TP4_Programacion_Grupo#.pdf** (# corresponde al número de grupo). El informe no debe superar las 5 páginas, sin contar apéndices.
- Subir al campus virtual únicamente el informe, en *Trabajos Prácticos > Entrega Informe 4*. La primera página debe contener el link al repositorio de GitHub.
- Antes de entregar, realizar el *commit* y *push* finales con el mensaje “Entrega final del TP”. La versión evaluada será la última disponible en GitHub al momento de la entrega; no realizar nuevos cambios después.
- **Cualquier detección de copia o plagio será sancionada.**

El objetivo de este trabajo es evaluar la predicción de informales utilizando técnicas de regularización y árboles de decisión. La idea es que usen aquellas variables socioeconómicas que hayan limpiado en el TP1 y TP2 y estén separadas en `ocupados_X_2025_MM` y `y_2025` como en el TP3. Es decir la base deberá contar con más de 15 variables y el rezago `y_2024` para poder extender los resultados de Maurizio & Monsalvo (2021).

A. *Modelo de Regresión Logística con Regularización: Ridge y LASSO*

1. Visualización: Grafiquen en dos paneles distintos los coeficientes de la penalidad de LASSO y Ridge para la grilla del parámetros de penalidad $\lambda = 10^n$ con $n \in \{-5, -4, -3, \dots, 4, 5\}$ e interpreten la regularización con cada penalidad. (*Hint*: en la función `LogisticRegression` la opción `C` es la inversa de la fuerza de penalidad, en lugar de `alpha`. Según el tamaño de su matriz, se recomienda probar con distintas opciones de `solver` para el uso eficiente computacional).
2. Penalidad óptima por Cross-validation y visualización: Usando `LogisticRegression CV` dividiendo la base 5 partes (5-fold), elijan la penalidad óptima λ en la grilla mencionada arriba. ¿Qué λ^{cv} seleccionó en cada caso? Generen box-plots mostrando la distribución del error de predicción para cada λ . Cada box debe corresponder a un valor de λ y contener como observaciones el error de clasificación de validación para cada partición. *Opcional*: para la regularización LASSO, generen un plot de puntos conectados, para la proporción de variables ignoradas por el modelo en función de λ , es decir la proporción de variables para las cuales el coeficiente asociado es cero.
3. Estimación con λ^{cv} y comparación de coeficientes: Estimen una **Regresión Logística** usando `ocupados_X_2025_MM` sin penalidad, con penalidad L1 y L2 siendo la penalidad óptima λ^{cv} elegida en el ítem anterior. Exporten una tabla con las siguientes columnas: (i) los coeficientes estimados para cada variable sin penalidad, (ii) coeficientes de penalidad L1, y (iii) coeficientes de penalidad L2. Interpreten los resultados de la tabla y conteste: ¿cómo son los coeficientes de la regularización con respecto a logit sin penalidad? ¿La penalidad L2 elimina variables de las que incluyeron en su matriz `ocupados_X_2025_MM`?

B. *Árboles*

1. Estimen un árbol de decisión podado (CART) eligiendo el hiperparámetro de costo de complejidad del árbol (`ccp_alpha`) con 5-fold Cross-

Validation. En un gráfico de línea, muestre el error de clasificación en función de la grilla de valores que uso para `ccp_alpha`. Comenten los resultados.

2. Visualización del árbol podado por cross-validation: En un panel A, muestren el gráfico del árbol que obtuvieron e interpreten. En un panel B, muestren en un gráfico la importancia de cada uno de los predictores. ¿Podría decirse que los coeficientes de las variables menos importantes son los que LASSO “achicó” a cero?

C. Comparación entre métodos

1. Computen la matriz de confusión ($p=0,5$), la curva ROC y las dos métricas que utilizó en el TP3. Comparen el desempeño de logit sin penalidad, logit con penalidad LASSO y Ridge, y el árbol de decisión. Comenten los resultados. ¿Qué pueden decir del trade-off entre comunicación de los resultados y performance predictiva? En este caso, ¿hay una ventaja por utilizar un método no lineal? Incorporen dentro de la justificación (1 - accuracy) para argumentar.
2. Recuerde que la Secretaría de Trabajo está interesada en identificar a grupos vulnerables para dirigir los recursos de un programa de trabajo. ¿Cambió su respuesta con respecto a cuál es el “mejor” modelo para asignar recursos escasos a los más necesitados?

D. Herramientas de IA y reflexión final.

A continuación, se solicita que desarrollen el uso de herramientas de Inteligencia Artificial a lo largo del trabajo, documentando lo realizado con las mismas y evaluar su aporte en este trabajo práctico.

1. Ítem final de reflexión (máximo 1 párrafo). Comenten cómo les ayudó la IA a programar: ¿en qué ítems fue más útil y en cuáles les resultó más difícil o menos efectiva? ¿Los ayudó en la interpretación?
2. Incluyan un Apéndice con todos los prompts de IA utilizados a lo largo del TP, copiados textualmente y en el orden en que fueron usados, y el nombre de la LLM utilizado (ChatGPT, Claude, Gemini, etc) .
3. Por último, reporten aproximadamente el tiempo total (en horas) dedicado a la realización de este trabajo práctico.